

Structure-Constrained Machine Translation (SCMT):

Inter-Rater Validation — Final Report

Gemina Intelligence LLC. — Pure Information Laboratory

2026-05-05 | v1.0 Final | N=20 pairs, 2 raters, 3 criteria

Abstract

本レポートはEXP-001の最終結果を報告する。EXP-001はGeminiAI物理推論エンジンが生成するStructure-Constrained Machine Translation (SCMT) 出力のヒューマン評価実験である。2名のバイリンガル評価者が独立してN=20件の英日翻訳ペアを3基準（C1: 主述関係の絶対固定、C2: 因果律の明示、C3: 代名詞・冗長性の排除）で評価した。評価者間一致度をCohen's κ で測定した結果、全基準で $\kappa=1.000$ (Almost Perfect) が確認された。C1・C2は合格率100%、C3は75%合格・5件失敗であり、失敗パターンはv1.5.0改善の具体的ターゲットを提供する。

Keywords: Structure-Constrained Machine Translation ・ Cohen's kappa ・ Inter-Rater Agreement ・ Bilingual Evaluation ・ GeminiAI ・ NOMOS

1. Introduction

NOOMOSエンジンはSCMTパイプラインを通じて日本語ナラティブ出力を生成する。通常の統計的機械翻訳と異なり、SCMTはAIIE物理フレームワークに由来する3つの不変条件を強制する。

- C1 — 主述関係の絶対固定: AIの出力がGold Narrativeの「誰が→何に→何をした」という骨格 (T01→T05→T09 binding) を維持しているか。
- C2 — 因果律の明示 (エネルギー勾配): 「～のため」「～により」といった論理の向きが正しく記述され、CFI場のエネルギー勾配方向を反映しているか。
- C3 — 代名詞・冗長性の排除 (最小作用の原理): 「それ」「彼」を具体名詞に置換し、読者の推論負荷を最小化しているか。

EXP-001は3つの問いに答えることを目的とする: (1) ルーブリックは独立した評価者が一貫して適用できるほど明確か? (2) 各基準の現在の合格率はどれくらいか? (3) v1.5.0で優先的に対処すべき失敗パターンはどれか?

2. Experimental Design

2.1 Sample Selection

GeminiAI本番コーパス (v31_states_core,

N=1,750件,

2026-05-05時点) から20件の英日ペアを抽出した。抽出基準:

- 6トピックドメイン (地政学・経済・健康・技術・法律・気象) にまたがる網羅性
- 単文から多節複文まで多様な構造的複雑さ
- 暗示的主語・専門用語・時制参照など構造的に挑戦的なケースを含む

2.2 Raters

	評価者A	評価者B
母語	日本語	日本語

英語力	上級	上級
評価者区分	バイリンガル友人	バイリンガル友人
事前調整	なし（独立評価）	なし（独立評価）

2.3 Evaluation Criteria

ID	基準名	物理的根拠	回答形式
C1	主述関係の絶対固定 (Subject-Predicate Invariance)	T01→T05→T09 TAG binding	はい / いいえ
C2	因果律の明示 (Causality Explicitness)	CFI場のエネルギー勾配方向	はい / いいえ
C3	代名詞・冗長性の排除 (Pronoun/Redundancy Elimination)	最小作用の原理 (記述長の最小化)	はい / いいえ

2.4 Inter-Rater Agreement Metric

Cohen’s κ を基準ごと・全体 (N=60評価) で算出した。回答は二値化（はい=1、はい（該当無し）=1、いいえ=0）。Landis & Koch (1977) スケールで解釈する。

κ 値	解釈
< 0.20	Slight (わずか)
0.21 - 0.40	Fair (まずまず)
0.41 - 0.60	Moderate (中程度)
0.61 - 0.80	Substantial (相当程度)
0.81 - 1.00	Almost Perfect (ほぼ完全) ← 本実験結果

3. Results

3.1 Inter-Rater Agreement (Cohen’s kappa)

基準	kappa	解釈	一致件数	Both PASS	Both FAIL
C1 主述関係	1.000	Almost Perfect	20/20	20件 (100%)	0件 (0%)
C2 因果律	1.000	Almost Perfect	20/20	20件 (100%)	0件 (0%)
C3 代名詞排除	1.000	Almost Perfect	20/20	15件 (75%)	5件 (25%)
Overall	1.000	Almost Perfect	60/60	55件 (91.7%)	5件 (8.3%)




Figure 1 — 評価者間一致度結果。左(A)：基準別PASS/FAIL件数。右(B)：全20件×3基準のPer-item一致度ヒートマップ（緑=両者PASS、赤=両者FAIL）。全基準でkappa=1.000。

3.2 Primary Finding

全3基準およびN=60件の総合でCohen's

kappa=1.000（完全一致）が確認された。この結果は以下を意味する：

- ・ SCMTループリックは、独立した人間評価者が事前の調整なしに一貫して適用できるほど明確に設計されている。
- ・ C1（主述関係）・C2（因果律）は現在の20件サンプルで検出可能な失敗を示さず、実装が正しく機能している。
- ・ C3（代名詞排除）は25%の失敗率（5/20件）を持つが、両評価者が同一の5件を不合格と判定しており、再現性は完全である。

3.3 C3 Failure Case Analysis

C3の5件失敗を以下に詳細分析する。注目すべきは、5件中いずれも「代名詞（それ・彼）の残存」ではなく、別の現象が原因であることである。

ID	Gold Narrative（問題箇所）	評価者Aコメント	評価者Bコメント	根本原因
803	「停電状態に置かれている」	（わかりづらい）	少し硬く、わかりづらい	語彙の硬さ（Lexical hardness）
998	「同人の行方を追っている」	（「同人」）	男の行方	法律語の漏出（Legal register leakage）
1143	「14%の速度で増加している」	（「速度」「増加」）	いいえ	英語からのカルク（Calque from EN）
1314	主語「米国」を挿入	（「米国」）	いいえ米国	暗示的主語の追加（Implicit subject insertion）
1933	「前日比30人増」	（前日比？）	いいえ（前日比？）	読者推論負荷（Reader inference burden）

重要な観察：5件の失敗はすべて「代名詞の残存」ではなく、C3基準が実際には「代名詞排除」より広い概念——構造的自然性（Structural Naturalness）——を測定していることを示す。この発見はv1.5.0での基準再定義の根拠となる。

4. Discussion

4.1 ルーブリック妥当性の確認

kappa=1.000は、3基準から成るSCMTルーブリックが評価可能なレベルで操作化されていることの強力な証拠である。異なる背景を持つ2名の評価者が独立に評価し、60件の判定で完全に一致した。この結果は、ルーブリックをN>=100規模の大規模評価ラウンドに展開可能であることを示す。

4.2 C3基準のスコープ問題と改定推奨

5件のC3失敗の分析から、現在の基準が2つの異なる現象を混在させていることが判明した：

- ・ C3a — 代名詞排除（元来の意図）：「それ」「彼」等の存在 → 本実験では一件も観測されず
- ・ C3b — 構造的自然性：カルク表現・暗示的主語挿入・レジスタ不一致・読者推論負荷

推奨：v1.5.0評価ラウンドでC3をC3a（代名詞排除・厳密）とC3b（自然性・読者推論負荷）に分割する。

4.3 Limitations

- ・ サンプルサイズ：N=20は基準妥当性の確認には十分だが、合格率の統計的推定には不十分。論文レベルにはN>=100を推奨。
- ・ 評価者プール：2名が同一のソーシャルネットワーク出身であり、暗黙の共通基準を持つ可能性がある。異なる職業背景の評価者の追加を推奨。
- ・ ドメインバランス：地政学が5件と過剰代表。将来のラウンドでは層別サンプリングを実施すべき。
- ・ kappa=1.000の天井効果：完全一致はアイテム難易度設定の反映である可能性がある。代名詞曖昧性や複雑な因果連鎖を含む難問を追加すべき。

5. Conclusion

EXP-001は3つの発見を確立した：

発見	結果	含意
F1 — ルーブリック明確性	kappa=1.000 (N=60)	ルーブリックはN>=100規模の評価展開に準備完了
F2 — C1/C2実装品質	合格率100%	主述関係・因果律制約は正しく実施されている
F3 — C3失敗パターン	5/20失敗 (25%), kappa=1.000	基準スコープの再定義が必要。5件は具体的改善ターゲット

kappa=1.000という完全評価者間一致は、EXP-001のヒューマン評価データがSCMTパイプラインの訓練・評価用グラントゥールースとして直接使用可能であることを意味する。C3で確認された5件の失敗は、評価者が一致して検証した具体的な改善事例であり、v1.5.0での優先的対処対象となる。

ルーブリックは検証された。次のステップはスケールである。

6. Recommended Next Steps

優先度	アクション	対象
P0	C3をC3a（代名詞排除） + C3b（自然性）に分割し評価ルーブリックを更新	v1.5.0ルーブリック改定
P0	失敗5件（ID: 803, 998, 1143, 1314, 1933）のSCMT出力を修正	本番コーパスパッチ
P1	N=100件の層別サンプリングによる拡大評価ラウンドを実施	論文レベル統計
P1	異なる職業背景の評価者をさらに2名追加招集	ソーシャルネットワークバイアス軽減

P2	代名詞曖昧性・複雑因果連鎖を含む難問アイテムを追加	天井効果の軽減
P2	NQM3.1査読結果後にEXP-001結果をMDPI Entropyへの付録として投稿	査読論文化